

Pharmacy assistant — POC et API par type de question

2026-09-22 · @Someone

Le POC en bref

Un patient peut interroger une base de médicaments et de pharmacies en darija, par écrit ou à la voix, et recevoir une réponse fiable et chiffrée.

Le POC démontre trois choses :

1. **Comprendre la darija** (arabe, latin ou « darija » avec chiffres, ex. 3andkom) grâce à un LLM few-shot qui renvoie une intention et des entités.
2. **Relier ce qui est dit à des données réelles** : fuzzy matching (RapidFuzz) contre un référentiel de médicaments (prix PPV, taux CNOPS/CNSS) et de pharmacies.
3. **Répondre sans inventer** : la réponse est construite à partir de modèles de phrases et des données trouvées, jamais générée librement. Un médicament incertain est présenté « à confirmer » et un nom non fiable n'est jamais affiché.

Hors périmètre : conseil médical, posologie, stock en temps réel, réservation.

Architecture

Chaque question passe par le même pipeline : transcription si c'est de l'audio, NLU, entity linking, puis une réponse construite par modèles de phrases.

```

flowchart LR
    U["U[Patient<br/>texte ou voix]"] --> F["F[Frontend React<br/>Vite, port 5173]"]
    F -->|audio| W["W[Whisper local<br/>faster-whisper small]"]
    W --> N
    F -->|texte| N["N[NLU<br/>LLM few-shot Ollama]"]
    N -->|intent + entités| M["M[Linking médicaments<br/>RapidFuzz + phonétique]"]
    N --> P["P[Linking pharmacies<br/>RapidFuzz]"]
    M --> R["R[Réponse par templates<br/>FR / darija]"]
    P --> R
    R --> F
  
```

Le NLU renvoie une intention et des entités (MEDICAMENT , DOSAGE , PHARMACIE , LOCALISATION). Le linking les rattache aux fichiers data/clean/medicaments_reference.csv (fusion AMMPS, CNOPS, CNSS) et data/clean/pharmacies_reference.csv .

Composant	Fichier	Techno
API	api/main.py	FastAPI, lancée avec uvicorn api.main:app --port 8000
Transcription	api/parole.py	faster-whisper, local, CPU int8
NLU	nlu/llm_prototype.py	gpt-oss:20b-ccloud via Ollama Cloud, exemples few-shot
Linking médicaments	nlu/entity_linking.py	RapidFuzz + clé phonétique + translittération
Linking pharmacies	nlu/pharmacy_linking.py	RapidFuzz sur nom et lieu
Langue de réponse	api/langues.py	détection FR / darija, textes traduits

La conversation est multi-tours : un session_id garde en mémoire le contexte, par exemple quand le bot attend une ville.

Les endpoints de l'API

L'API expose 7 endpoints. /chat et /chat/audio servent l'assistant ; les autres servent les pages de recherche du front et le diagnostic. La documentation interactive est sur <http://localhost:8000/docs>.

Méthode	Endpoint	Rôle	Entrée principale
POST	/chat	Répond à une question écrite (pipeline complet)	JSON {text, session_id?}
POST	/chat/audio	Répond à une question vocale (audio, puis même pipeline que /chat)	formulaire fichier , session_id? , langue?
POST	/transcription	Transcrit l'audio seulement, pour que l'utilisateur relise avant d'envoyer	formulaire fichier , langue?
GET	/medicaments	Recherche un médicament par nom ou DCI	q , dosage? , limit (1 à 30, 12 par défaut)
GET	/pharmacies	Recherche une pharmacie par nom et/ou ville	q? , ville? , limit

Méthode	Endpoint	Rôle	Entrée principale
GET	/schema	Renvoie la taxonomie des intentions et entités du NLU	aucune
GET	/health	Vérifie que l'API tourne	aucune

Tous les champs de /chat en sortie :

Champ	Contenu
session_id	identifiant de conversation, à renvoyer au tour suivant
reply	la réponse en langage naturel, dans la langue du patient
intent, entities	ce que le NLU a compris
medicament_matches, pharmacie_matches	les fiches trouvées dans les référentiels
alternatives	les équivalents moins chers, si demandés
awaiting_localisation	true si le bot attend une ville
langue, note_lieu, note_garde	langue de réponse et avertissements
validation_errors	écarts entre la sortie du LLM et le schéma attendu

API par type de question

Toutes les questions écrites passent par POST /chat . Ce qui change d'une question à l'autre, c'est l'intention détectée par le NLU, donc la branche de traitement. Le NLU connaît 8 intentions (GET /schema). Tous les exemples ci-dessous sont de vraies réponses de l'API, obtenues le 22 septembre 2026.

Intention	Exemple de question	Traitement	Données renvoyées
prix_remboursement	chhal taman doliprane 1000 w wach kayt3awed?	linking médicament + dosage	prix PPV, taux CNOPS/CNSS

Intention	Exemple de question	Traitement	Données renvoyées
disponibilite_medicament	3andkom augmentin?	linking médicament, puis demande la ville (multi-tours)	fiche + pharmacies proches
alternative_moins_chere	wach kayn chi haja rkhes mn augmentin 1g?	même DCI et même dosage, triés par prix	alternatives
info_pharmacie	fin kayna pharmacie de garde f hay riad rabat?	linking pharmacie par nom et/ou lieu	nom, téléphone, adresse, garde
posologie_information	kifach nakhod spasfon?	fiche du médicament, pas de posologie	fiche + renvoi à la notice
conseil_medical	rasi kaywja3ni bzaf chno nakhod?	refus volontaire, aucune fiche affichée	numéros d'urgence
salutation	salam	réponse fixe	présentation du bot
hors_sujet	chno l jaw ghedda?	réponse fixe	rappel du périmètre

1. Prix et remboursement

Requête :

```
POST /chat
{ "text": "chhal taman doliprane 1000 w wach kayt3awed?" }
```

Le NLU extrait **MEDICAMENT** = doliprane et **DOSAGE** = 1000 . Le matcher trouve DOLIPRANE avec un score de 100 et une confiance **auto** , puis choisit la variante qui a un prix.

Réponse (extrait) :

```
{
  "intent": "prix_remboursement",
  "langue": "ary_lat",
  "entities": [
    { "type": "MEDICAMENT", "value": "doliprane" },
    { "type": "DOSAGE", "value": "1000" }
  ],
  "reply": "DOLIPRANE (1 G, comprime effervescent) -- 13.7 DH, remboursement 70% (CNOPS w CNSS)",
  "medicament_matches": [
    {
      "nom_candidat": "DOLIPRANE",
      "score": 100.0,
      "confidence": "auto",
      "nb_variantes": 22,
      "variantes": [
        { "dci": "PARACETAMOL", "dosage": "1 G", "forme": "COMPRIME EFFERVESCENT",
          "taux_remboursement_cnops": 70.0, "taux_remboursement_cnss": 70.0 }
      ]
    }
  ]
}
```

La même question en arabe (بشال الدوليبران ؟) retrouve aussi DOLIPRANE, avec un score de 95 grâce à la translittération. La réponse revient en graphie arabe (langue = ary_ar).

2. Disponibilité d'un médicament (deux tours)

Tour 1: { "text": "3andkom augmentin?" }. Le bot présente la fiche et demande la ville.

```
{
  "session_id": "3f1c...",
  "intent": "disponibilite_medicament",
  "awaiting_localisation": true,
  "reply": "AUGMENTIN (...) -- 157.2 DH, remboursement 70% (CNOPS w CNSS)\n\u0641\u064a\u0646\u0627 \u0645\u062f\u0627 \u0641\u0627 \u0646\u0627 \u0628\u0627\u062d \u0646\u0642\u062a\u0631\u0629 3 \u0644\u064a\u0643 \u0641\u0627\u0631\u0645\u0627\u0639\u064a\u0629 \u062a\u0631\u064a\u0628 \u0644\u064a\u0647\u0645 ?"
}
```

Tour 2: { "text": "maarif", "session_id": "3f1c..." }. Le session_id indique que « maarif » répond à la question précédente. L'API renvoie 3 pharmacies du Maarif à Casablanca. Elle signale aussi qu'un lieu « maarif » existe à Sidi Bennour (note_lieu).

```
"pharmacie_matches": [
  { "nom": "Pharmacie Route d'Eljadida", "telephone": "0522995746",
    "adresse": "240 route d' El Jadida Maarif Casablanca", "ville":
    "Casablanca",
    "garde": "garde 24h/24", "confidence": "liste_localisation" }
]
```

3. Alternative moins chère

{ "text": "wach kayn chi haja rkhes mn augmentin 1g?" } : l'API cherche les produits de même DCI (amoxicilline + acide clavulanique) et de même dosage, triés du moins cher au plus cher.

```
"alternatives": {
  "reference": { "nom": "AUGMENTIN", "dci": "AMOXICILLINE // ACIDE
  CLAVULANIQUE",
    "dosage": "1 G / 125 MG", "forme": "SACHET", "ppv": 118.0 },
  "equivalents": [
    { "nom": "NEOCLAV", "forme": "SACHET", "ppv": 82.2, "meme_forme": true },
    { "nom": "LEVAMOX", "forme": "SACHET", "ppv": 86.9, "meme_forme": true }
  ]
}
```

Sur les 6 équivalents trouvés, le moins cher économise 35,8 DH. La réponse rappelle que le changement se décide avec le pharmacien.

4. Information sur une pharmacie

{ "text": "fin kayna pharmacie de garde f hay riad rabat?" } : le NLU extrait LOCALISATION = hay riad rabat. L'API renvoie 3 pharmacies de Rabat. Comme le mot « garde » apparaît, elle ajoute note_garde : l'annuaire est une photo figée, les gardes changent chaque jour.

5. Posologie, conseil médical : les refus volontaires

- **Posologie** (kifach nakhod spasfon?) : la base ne contient pas de posologie. L'API affiche la fiche SPASFON (26,2 DH) et renvoie vers la notice ou le pharmacien.
- **Conseil médical** (rasi kaywja3ni bzaf chno nakhod?) : aucun médicament n'est proposé, même s'il en est cité un. La réponse oriente vers un professionnel et donne le SAMU (141), la Protection civile (15) et le Centre antipoison (0801 000 180).

6. Médicament inconnu

`{ "text": "3andkom qwertyzol?" }` : le NLU extrait bien un médicament, mais le matcher le classe `non_fiable`. L'API ne montre donc aucune fiche et demande de vérifier l'orthographe. Sans ce filtre, un nom inventé recevait le prix d'un vrai médicament.

Recherche directe, sans NLU

Les pages Médicaments et Pharmacies du front appellent les matchers directement :

```
GET /medicaments?q=doliprane&limit=2
GET /pharmacies?ville=maarif&limit=2
→ { "resultats": [ { "nom": "Pharmacie Route d'Eljadida", ... } ],
    "note": "'maarif' existe aussi a : Sidi Bennour. ..." }
```

Questions vocales

Une question vocale est d'abord transcrite par Whisper en local, puis traitée exactement comme `/chat`. Il y a deux façons d'appeler l'API.

```
sequenceDiagram
    participant F as Frontend
    participant A as API
    participant W as Whisper local
    participant N as NLU + linking
    F->>A: POST /transcription (audio)
    A->>W: transcrire(audio, amorce)
    W-->>A: texte + langue + confiance
    A-->>F: texte à relire
    F->>A: POST /chat (texte corrigé)
    A->>N: même pipeline que le texte
    N-->>A: intent, fiches
    A-->>F: reply
```

- **En deux temps** (`/transcription` puis `/chat`) : l'utilisateur relit le texte avant de l'envoyer. C'est le mode utilisé par l'interface, car Whisper ne connaît la darija qu'approximativement.
- **En un appel** (`/chat/audio`) : audio, transcription et réponse en une seule requête, avec le même `session_id` multi-tours.

Requête (formulaire multipart) :

```
curl -X POST http://localhost:8000/chat/audio \
-F "fichier=@question.webm" \
-F "langue=ar"
```

La réponse reprend tous les champs de `/chat`, plus un objet `transcription` :

```
"transcription": {
  "texte": "<ce que Whisper a entendu>",
  "langue": "ar",
  "confiance_langue": 0.0,
  "duree_audio": 0.0,
  "avertissement": null
}
```

Règle	Valeur	Pourquoi
Durée max	60 s	au-delà, la transcription sur CPU est trop lente pour un chat
Taille max	10 Mo	même raison
Langues forcées possibles	ar, fr	détection automatique sinon
Seuil de confiance	0,6	en dessous, <code>avertissement</code> invite à relire le texte
Erreur audio	HTTP 422	fichier vide, trop long, trop lourd ou illisible

Whisper reçoit une amorce avec les noms de médicaments les plus demandés (Doliprane, Spasfon, Augmentin...). Sans elle, « Spasfon » ressortait par exemple en « space fond ».

Services et modèles externes

Un seul service distant est appelé à chaque question : le LLM du NLU. Tout le reste tourne en local.

Service	Où	Rôle	Pourquoi ce choix
Ollama Cloud, modèle gpt-oss:20b-cloud	distant, API compatible OpenAI (/v1/chat/completions), clé OLLAMA_API_KEY	intention + entités en JSON	le few-shot gère la darija sans entraîner de modèle ; modèle changeable par OLLAMA_MODEL
faster-whisper small	local, CPU, int8	transcription audio	gratuit, pas d'envoi de la voix du patient ; ~460 Mo téléchargés au premier appel
RapidFuzz	local	rapprochement des noms (fautes, graphies)	rapide et déterministe : pas d'invention possible
Référentiels CSV	local, data/clean/	médicaments (AMMPS, CNOPS, CNSS) et pharmacies	sources officielles fusionnées

La réponse n'est pas générée par un second appel au LLM. Elle est assemblée à partir de modèles de phrases, ce qui réduit la latence et le coût, et évite qu'un prix soit inventé.

Limites du POC et pistes d'amélioration

Le POC répond juste sur les 11 questions testées, mais plusieurs choix ne tiendraient pas en production.

Limite	Conséquence	Piste
Pas de stock en temps réel	le bot ne peut pas dire si un médicament est disponible, seulement où appeler	partenariat avec des pharmacies ou un grossiste
Gardes figées dans l'annuaire	la pharmacie de garde du jour peut être fausse	source quotidienne des gardes
Sessions en mémoire	perdus au redémarrage, un seul processus	Redis ou base de données

Limite	Conséquence	Piste
Whisper sans darija	transcriptions approximatives	amorce enrichie, ou modèle affiné sur de la darija
Dépendance à Ollama Cloud	pas de réponse sans réseau ni clé	modèle local ou classifieur de secours
Pas d'authentification	API ouverte à quiconque la joint	clé d'API, limitation de débit
Prix manquants pour certaines variantes	fiche sans prix	compléter le référentiel