



DwaTalk — Point d'avancement

Assistant pharmacie conversationnel en darija, arabe et français, à l'écrit ou à la voix

Challenge #1

21 septembre 2026

Équipe DwaTalk

OBJECTIF

Comprendre la demande d'un patient et la relier aux bases officielles marocaines pour répondre avec des informations vérifiées : prix, remboursement, équivalents, pharmacies.

● 9 étapes terminées

● 1 en finalisation

● 4 à venir

19 974

médicaments
3 sources
fusionnées

2 652

pharmacies
saydalia.ma


98,2 %

intention exacte
baseline : 62,7 %

97,6 %

F1 entités
110 phrases

ARCHITECTURE — DU SCRAPING À LA RÉPONSE



ÉTAPES RÉALISÉES ET TECHNOLOGIES

1 Collecte des données (scraping)

● Terminé

496 pages AMMPS scrapées ; API JSON de la CNSS repérée par inspection réseau ; carte saydalia.ma interrogée sur ~70 villes ; liste CNOPS 2014 (Excel). **Extraction CNSS complète : 8 991 / 8 991.**

Python

requests

BeautifulSoup

openpyxl

2 Nettoyage & fusion des référentiels

● Terminé

Normalisation des textes, prix et taux ; fusion des 3 sources sur la clé nom + dosage + forme, sans doublons. **19 974 médicaments (remboursement +76 %), 2 652 pharmacies.**

pandas

unicodedata

regex

CSV

3 Taxonomie & corpus annoté

● Terminé

8 intentions (disponibilité, prix, équivalent, pharmacie, posologie, conseil médical...) et 6 entités. **121 phrases annotées** : français, arabe, darija (2 graphies), mixte.

schema.json

JSONL

Python

4 Compréhension du langage (NLU)

● Terminé

LLM few-shot (taxonomie + 11 exemples, température 0), sortie JSON validée. Comparé à une baseline TF-IDF + régression logistique. **Intention 98,2 % contre 62,7 %.**

Ollama Cloud

gpt-oss:20b

scikit-learn

5 Entity linking

● Terminé

3 recherches floues (nom, molécule, phonétique), filtre par dosage, paliers de confiance : un résultat « non fiable » n'est jamais affiché. Équivalents moins chers ; pharmacies par ville puis nom. **36/37 médicaments en top-1, 12/12 pharmacies.**

RapidFuzz

pandas

6 Translittération arabe ↔ latin

● Terminé

Pont entre la graphie arabe (sortie de la voix) et les bases en latin : translittération puis clé phonétique commune. دوليبران et DOLIPRANE ont la même clé. **19 des 37 cas testés en arabe.**

Python

unicodedata

regex

7 Reconnaissance vocale

● Terminé

Whisper « small » en local (CPU, int8), ~3 s par question, sans coût. Amorce de noms de médicaments ; transcription douteuse signalée et **relue par l'utilisateur** avant envoi.

faster-whisper

CTranslate2

MediaRecorder

8 API & gestion du dialogue

● Terminé

5 routes REST, réponse adaptée à chaque intention, dialogue multi-tours (« dans quelle ville ? »). **Garde-fous : conseil médical orienté vers un professionnel, rien d'inventé.**

FastAPI

Uvicorn

Pydantic

9 Interface web

● Finalisation

6 pages : chat écrit et vocal, fiches médicament (prix, remboursement, équivalents), pharmacies avec plan, historique local. **Refonte visuelle en cours.**

React 19

Vite

React Router

OpenStreetMap

10 Tests & évaluation

● Terminé

264 tests automatisés (routage, linking, API, voix) en quelques secondes, sans réseau ; 4 scripts d'évaluation : NLU, baseline, médicaments, pharmacies.

pytest

scikit-learn (métriques)

RÉSULTATS

Intention — exactitude **98,2 % / 62,7 %**

Entités — F1 **97,6 % / 95,4 %**

■ LLM few-shot ■ Baseline TF-IDF

DIFFICULTÉS & LIMITES

- Pas de modèle darija dans Whisper : compensé par relecture et translittération.
- Pas de stock en temps réel : orientation vers des pharmacies.
- Bases administratives : pas de posologie.
- Corpus rédigé par l'équipe, pas de messages réels.

PROCHAINES ÉTAPES

- Finaliser et tester l'interface web.
- Évaluer sur de vrais messages et audios en darija.
- Améliorer la voix darija (affinage de Whisper).
- Déployer une démo en ligne.